

التوليد المعزز بالاسترجاع

دليل شامل للهندسة المعمارية والتطورات ومستقبل الذكاء الاصطناعي المؤسس

التاريخ: نوفمبر 2025

ما هو RAG؟

التحدي الأساسي

نماذج اللغة الكبيرة (LLMs) تتذكر فقط ما تعلمته أثناء التدريب. مثل طالب عبقرى لكنه كثير النسيان - لا يمكنه الوصول إلى معلومات جديدة أو محدثة.

الحل: RAG


التوليد المعزز بالاسترجاع يمكّن LLMs من استشارة مصادر معرفة خارجية وموثوقة في الوقت الفعلي قبل الإجابة على الأسئلة.

الفوائد الرئيسية

- ✓ منع "الهلوسات" (Hallucinations)
- ✓ ضمان الاتساق الواقعي
- ✓ الملاءمة للمجالات المحددة
- ✓ الوصول إلى البيانات المحدثة

المكون 2
المولد (LLM)

المكون 1
المسترجع



الجيل الأول (2020)


Naive RAG

عملية مباشرة بخطوة واحدة: استرجاع من قاعدة المعرفة ثم توليد الإجابة.

► وصول إلى معرفة خارج بيانات التدريب

► ضمان الاتساق الواقعي

► بساطة التنفيذ



الجيل الثاني

Advanced RAG

تحسين أجزاء النظام: استرجاع أكثر دقة، هيكل أفضل لقاعدة المعرفة.

► تحسين الاستعلام (Query Optimization)

► التحكم في الدقة (Granularity Control)

► إعادة ترتيب النتائج (Re-ranking)

الجيل الثالث

Modular RAG

نظام مرن مع مكونات متعددة وقدرات استدلال متقدمة.

► وحدات الذاكرة (Memory Modules)

► موجهات الاستعلامات (Smart Routers)

► الاستدلال متعدد الخطوات (Multi-step Reasoning)

أنماط التصميم المعماري

النمط 1

Retriever-Centric

”إدخال غير مرغوب فيه، إخراج غير مرغوب فيه” - نجاح النظام يعتمد على العثور على أفضل المعلومات.

التقنيات الرئيسية:

- تحسين الاستعلام
- التحكم في الدقة
- إعادة ترتيب النتائج
- تحسين الفهرسة

النمط 2

Generator-Centric

التركيز على سلوك LLM - ضمان أن يكون الإخراج مؤسسًا بدقة في الأدلة المسترجعة.

التقنيات الرئيسية:

- النقد الذاتي
- طبقات التحقق
- فك التشفير المقيد
- آليات الإخلاص


النمط 3

Hybrid/Adaptive

الجمع بين أفضل ما في العالمين - نظام ديناميكي ومرن يتكيف مع المتطلبات.


التقنيات الرئيسية:

- الاسترجاع التكراري
- الاسترجاع التكيفي
- الاستدلال متعدد الخطوات
- التوجيه الذكي



تقنيات RAG المتقدمة

المكون	التقنية	الأمثلة
الاسترجاع	تحسين الاستعلام إعادة صياغة الاستعلام لتحسين دقة البحث	RQ RAG Semantic Router
الاسترجاع	تحسين الفهرسة تنظيم قاعدة المعرفة بدقة أعلى	LongRAG Knowledge Graphs
التوليد	تنسيق السياق إزالة المعلومات غير ذات الصلة	Re-rankers LongLLMLingua
التوليد	آليات الإخلاص التحقق الذاتي من الدقة الواقعية	Self-RAG INFO RAG
هجين/تكيفي	الاسترجاع التكراري متابعة سلسلة من المراجع	ITER-RETGEN RAPTOR
هجين/تكيفي	الاسترجاع التكيفي البحث فقط عند الحاجة	FLARE Adaptive Retrieval



التحقق من المسترجع

مقاييس جودة السياق

- ▶ **الملاءمة السياقية:** هل المستندات المسترجعة ذات صلة بسؤال المستخدم؟
- ▶ **الاستدعاء السياقي:** هل تم العثور على جميع المعلومات الضرورية؟
- ▶ **الدقة السياقية:** هل أهم المعلومات في الترتيب الأول؟


التحقق من المولد

مقاييس جودة الإجابة

- ▶ **ملاءمة الإجابة:** هل تعالج الإجابة السؤال الأصلي مباشرة؟
- ▶ **الإخلاص/التأسييس:** هل يمكن تتبع كل عبارة إلى المستندات المسترجعة؟

⚠ المقاييس الأساسي

الإخلاص (Faithfulness) هو أهم مقياس - الدفاع الأساسي ضد الهلوسات والمعلومات المختلقة.



التطبيقات الصناعية

القانون والامتثال

بحث الامتثال التنظيمي

تلخيص فوري لقوانين وقرارات الحالة لضمان امتثال الشركة للوائح الأخيرة.

⚙️ RAG خاص بالمجال (Domain-specific RAG)

الرعاية الصحية

دعم القرار السريري

إجابات سريعة ومؤسسية للأسئلة الطبية المعقدة بالاستناد إلى السجلات الطبية والأدبيات.

⚙️ RAG متعدد الوسائط (Multimodal RAG)

التمويل

التحليل المالي

تحليل آلاف التقارير والإيداعات الفصلية لاستخراج المقاييس المالية الرئيسية ومخاطر الامتثال.

⚙️ فهرسة متقدمة للبيانات المعقدة

خدمة العملاء

الدعم الآلي

روبوتات محادثة توفر دعمًا دقيقًا وشخصيًا بناءً على قاعدة معرفة الشركة المحدثة.


⚙️ RAG تكراري للمحادثات متعددة الأدوار

الهندسة

الوثائق الفنية

استكشاف الأخطاء وإصلاحها في الآلات المعقدة من خلال استعلام الوثائق الضخمة بدقة.

⚙️ استرجاع وإع بالدقة (Granularity-aware)



التحديات الحالية

تحدي قابلية التوسع

التكلفة والوقت المطلوبان للحفاظ على قواعد بيانات متجهات ضخمة وإجراء عمليات بحث في الوقت الفعلي يصبحان هائلين مع نمو البيانات.

مشكلة "الإبرة في كومة القش"

فشل LLM في التركيز على الحقائق الحاسمة عندما يكون السياق المسترجع طويلاً جداً، مما يؤدي إلى فقدان المعلومات المهمة.

الثقة والشفافية

صعوبة تتبع سبب الإجابة الخاطئة - هل فشل المسترجع (بحث سيء) أم المولد (توليد سيء)؟ تحسين القابلية للتفسير أمر حاسم.

مستقبل RAG

استرجاع أكثر ذكاءً وديناميكية


أنظمة تقرر متى تبحث، وعما تبحث، وكيف تجمع المعلومات من مصادر متعددة، بسلوك يشبه الباحث البشري.

التكامل متعدد الوسائط

التعامل مع جميع أشكال البيانات - نص وصور وفيديو وصوت - لتوفير إجابات شاملة وحقيقية.

التكامل مع رسوم المعرفة

دمج RAG مع قواعد بيانات معرفة منظمة يمكن الاستدلال المعقد متعدد القفزات الذي يتجاوز استرجاع الحقائق البسيط.



شكراً لك

أسئلة ومناقشة

نرحب باستفساراتكم وملاحظاتكم حول التوليد المعزز بالاسترجاع (RAG) والتطبيقات العملية في مؤسستكم.

